

knowpipe：从技术资料中找到下一步阅读

基于 Spark 与 MongoDB 的多源技术资料分析与个性化推荐 Web 系统

12 篇中文全文

本次实际网页演示
Python 7篇 + Django 5篇

10'215 篇背景

独立的规模与质量验证
真实语料，不与演示混淆

一个核心问题

已读之后，下一篇资料
能否直接帮助当前目标？

陶文杰 / 陈铭宇 · 2026-09-25 · 当前部署：单台电脑

工程流程可以演示；011核心推荐质量尚未通过°

用户流程：目标 → 材料 → 阅读 → 再推荐

01 输入中文目标

围绕具体技术问题

02 查找多源全文

先判断正文是否相关

03 给出原文依据

展示重合/可能补充

04 阅读中文全文

保留来源和处理状态

05 主动标记已读

记录本次正文版本

06 再次计算推荐

历史确实进入处理

已读 ≠ 掌握；不同来源 ≠ 必然有新知识°

四层架构：Spark真实参与‘长任务交给worker

Web交互层

中文目标 · 推荐列表 · 全文阅读 · 主动已读

业务层

Flask鉴权 · 任务队列 · worker租约 · 翻译/通知门控

数据管理与挖掘层

MongoDB原文/版本/历史 · 有界语义特征 · 选择规则

Spark处理层

全文索引 · 全库召回 · 特征聚合 · 覆盖/补充/去重

本次：单机 Spark

local模式真实执行
不是跨主机集群
Web不在HTTP内重算

先正确 · 再扩容

扩容可改善容量/吞吐
不会自动提高相关性
也不能修复翻译含义

多源数据：规模证据和演示数据分别说明

Stack Exchange 技术问答

10'167

postgreSQL 官方文档

24

Docker 官方文档

12

Python 官方文档

7

Django 官方文档

5

背景合计 10'215

用于011冻结质量评价
来源与正文版本可追溯

本次演示 12 篇

Python 7 + Django 5
原生中文官方全文
不冒充全库中文翻译

来源：009 scale.json / corpus manifest° 镜像平台不重复计作独立内容来源°

核心算法：相关性先于“与已读不同”

1 全文召回

spark词汇索引
技术对象与正文过滤

2 有界语义比较

原中文目标相关性
候选与已读上下文

3 聚合并选择

相关度 + 可能补充
- 已读覆盖 - 列表
重复

4 返回证据

双方原文` 版本` 位置
不确定范围明确可见

最多100篇候选` 共300段正文；输出最多3项

模型只提供特征；自定义规则借鉴覆盖与MMR° 不能把“换个说法”当成新知识°

实际页面：保存中文目标并查看推荐



实际工程流程

中文目标真实保存

生产Spark返回结果

首轮偏题仍存在
质量未通过

阅读与已读：行为改变可追踪



原生中文全文阅读



显式已读记录



已读后的真实重算

RSS：真实音频已经进入推荐，但闭环仍有限

已经实际完成

真实RSS条目与公开音频
完整音频进入ASR
产生2961字符全文
全文入库并实际入选

尚未通过或未验证

播客中文本轮未就绪，零通知
转写没有独立逐字金标准
三分支补充通知仍待验证
不能据首次失败说重试耗尽

RSS提供增量资料；最终仍须接受相同目标相关性和已读比较门槛°

质量评价：保留真实失败，不把能运行当效果好

17个冻结场景，35个返回项，四个技术主题

直接有帮助 13

部分相关 13

无关 9

37.1% 直接相关

宽松计部分相关为74.3%
仍未达到冻结80%门槛

11 条错误补充

另有12条解释依据不足
同义复述误报仍存在

字面 ≠ 语义

348处原文位置校验通过
不能抵消推荐含义错误

含明确受控场景；代理原文审核，不是学生学习提升实证。

SDD与分工：需求、代码、证据能够对上

可追溯过程

spec / plan / tasks / contracts

冻结输入 → 实现 → 原文核验

Git真实提交 + 提示词来源归档

最终分工（用户已确认）

陶文杰：数据、Spark、算法评价 50%

陈铭宇：Mongo、API、Web/材料 50%

与初版分工无调整

六项交付

源码URL与Git、需求/设计与提示词、项目报告

≤5分钟MP4、分组分工表、可编辑汇报PPT

下一步：先解决用户价值，再扩大规模

01 找对材料

正文直接回答目标
区分错误技术对象
用独立原文事实验收

02 解释对价值

同义复述不算新增
双方证据不足就保留不确定
完成正负通知对照

03 读懂中文

远程4次调用鉴权失败
先解决HTTP 401，再核对语义
失败不回退本地或收费

质量达到门槛以后，再决定增加语料，并发与跨主机Spark°

当前结论：工程演示与质量验证分开，所有失败和依赖如实保留°